

2026 《人工智能导论》大作业报告

任务名称：可解释的谣言检测

小组人员：待填写

代码仓库：https://github.com/SiriThree/Rumor_Classify

1. 任务目标

本项目面向英文社交媒体推文的谣言检测任务，输入一条推文后输出二分类结果与相应判断依据。我们以 `val.csv` 上的准确率和可解释性为核心目标，构建了“Transformer 主分类 + 检索证据 + 规则纠偏 + 解释生成”的复合系统，在保证可复现的前提下尽量提升检测效果。

2. 具体内容

(1) 实施方案

最终方案采用 BERTweet 作为主分类器，对 `tweet` 进行二分类微调；同时使用 `lexical retrieval` 与 `dense retrieval` 从训练集检索相似样本，并通过 RRF 进行混合排序。对于高风险样本，系统再结合证据一致性、官方通知模式、`rumor amplification` 模式和安全通知模式进行纠偏，最后输出预测标签和解释文本。

- 主分类器：vinai/bertweet-base，适合 `tweet` 语域。
- 检索证据：稀疏检索 + 句向量检索。
- 融合策略：强一致覆盖、证据冲突复判、官方更新修正、`rumor amplification` 修正、安全通知修正。
- 解释模块：基于文本信号、相似证据和最终标签生成中文判断依据。

(2) 核心代码分析

系统主流程集中在 `src/rumor_system/pipeline.py`。`dataset.py` 负责数据读入与规范化；`transformer.py` 负责 BERTweet 的训练、保存和推理；`hybrid.py` 将 `lexical` 与 `dense` 两路证据进行融合；`pipeline.py` 中的 `fuse_prediction` 实现了检索增强决策逻辑，是本项目提分的关键模块。

- 数据层：读取 `id`、`text`、`label`、`event`，并生成 `normalized_text`。
- 模型层：对 BERTweet 进行监督微调，输出 `label` 与 `confidence`。
- 检索层：从 `train.csv` 中找相似推文，为预测提供证据支持。
- 决策层：围绕高频错例做窄规则修正，而不是全局硬覆盖。

(3) 检测结果分析

最终稳定主线在 val.csv 上达到 363/401，准确率 90.52%。从实验过程看，真正有效的提升主要来自“检索证据 + 面向错例的定向纠偏”，而不是盲目换 backbone 或直接引入 LLM 改判。我们还验证了事件前缀输入和 LLM semantic analyzer，两者在当前数据上都没有带来净收益。

方案	准确率	说明
Hybrid Retrieval	84.29%	仅使用检索投票
BERTweet + Hybrid	85.54%	Transformer 主分类 + 检索
BERTweet + Rules	89.28%	加入证据冲突与官方更新纠偏
Event Prefix	87.03%	显式加入事件前缀，效果下降
LLM Semantic	86.03%	真实 LLM 语义改判，整体下降
Final Mainline	90.52%	加入 rumor amplification 与安全通知纠偏




图 1 不同方案在验证集上的准确率对比

从事件维度看，Germanwings 与 SydneySiege 最难，准确率分别为 80.43% 和 88.43%；Ferguson 为 90.83%，Ottawa 为 94.38%。这说明数据中的错误并非随机分布，而是高度依赖事件语境与表达模式。




图 2 各事件子集上的准确率

需要说明的是，训练集与验证集覆盖相同事件集合，因此当前高准确率部分受益于事件内相似表达、近重复模板和检索增强能力。也就是说，该结果在当前验证集上有效，但对全新事件的泛化能力仍需进一步验证。

（4）判断依据的分析（可解释性等）

解释模块并不让大模型直接决定标签，而是基于最终预测、相似训练样本、top evidence 标签和置信度生成中文判断依据。新版 explanation 采用“三段式”结构：先说明当前 tweet 在传播中扮演的角色，再指出触发判断的关键短语，最后补充检索证据如何支持或限制该结论。这样既能提高可读性，也能让判断依据更加贴近真实决策过程。

- 对于 rumor amplification 类文本，系统更关注“未证实指控的传播作用”，而不是表面情绪强弱。
- 对于官方公告、安全通知、课程取消等文本，系统更关注“通知角色”，而不是事件背景中的 shooting/lockdown 词汇。
- 对于 headline-style 新闻快讯，系统会优先结合 top evidence 与事件风格判断其是否真正属于 rumor thread。

示例类型	输入文本片段	中文判断依据示例
安全通知	UPDATE: #uOttawa courses + exams officially cancelled... Lockdown still in effect. Stay indoors, stay safe...	该推文被判定为非谣言，因为它在传播中更像一条机构安全通知。“officially cancelled” “lockdown still in effect” “stay indoors” 等表达体现了事务安排和安全指令

		属性，而不是未证实指控的传播。
谣言式传播	Shoot unarmed kid. Conceal evidence. Impose martial law. Smear the victim...	该推文被判定为谣言，因为它在传播中更像一条对未证实指控的谣言式传播。“conceal evidence”“smear the victim”“martial law”等表述带有强指控和放大传播特征，检索到的相似样本也支持这一判断。

表 1 中文判断依据示例

3. 工作总结

(1) 收获、心得

本次大作业最大的收获是认识到：rumor detection 并不等同于真假判断。很多文本是否属于 rumor，更取决于它在事件早期传播中的角色。单纯依赖表层词汇或情绪强度容易产生伪相关，只有把深度学习、检索证据和错误分析结合起来，系统效果才会稳定提升。

(2) 遇到问题及解决思路

项目中遇到的主要问题包括：headline false alarm、opinion-like rumor miss、检索证据带偏，以及在线接口推理较慢。对应地，我们通过错误样本分型、增加缓存、放弃副作用较大的 LLM 改判、保留有效的窄规则纠偏，最终将主线准确率提升到了 90.52%。

4. 课程建议

如果后续课程继续使用类似任务，建议在数据中提供 conversation thread、source tweet、reply 关系、发布时间或来源类型等上下文信息。对于 PHEME 风格任务，单 tweet 分类天然受限；若能加入 thread 结构和时间线信息，模型的真实性能与可解释性都还有明显提升空间。